

Classificação de Transações Fraudulentas de Cartão de Crédito: uma Abordagem de Aprendizado de Máquina com scikit-learn

Anna Julia Santos de Paula ¹ Eduarda Dantas Azevedo Silva ² Sara de Oliveira Silva Omena ³

Faculdade de Computação e Informática (FCI)
Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

<10420681@mackenzista.com.br
, 10419951@mackenzista.com.br, 10425441@mackenzista.com.br>

2026

Resumo

O crescimento do comércio eletrônico e da digitalização dos meios de pagamento ampliou de forma expressiva o volume de transações por cartão de crédito, favorecendo também o aumento das fraudes financeiras. A identificação de transações fraudulentas constitui um problema clássico de Aprendizado de Máquina, marcado pelo forte desbalanceamento entre classes, uma vez que as fraudes representam apenas uma fração ínfima do total de operações. Este trabalho tem como objetivo desenvolver e avaliar modelos de classificação capazes de identificar transações fraudulentas de cartão de crédito a partir de uma base de dados pública, disponibilizada na plataforma Kaggle, composta por 284.807 transações realizadas por portadores europeus em setembro de 2013, das quais apenas 492 (0,17%) são fraudulentas. Justifica-se o estudo pela relevância econômica da detecção automatizada de fraudes, uma vez que abordagens manuais ou baseadas em regras fixas mostram-se insuficientes diante do volume e da velocidade das transações atuais. Metodologicamente, o trabalho segue a Opção Framework, empregando a biblioteca scikit-learn para a resolução de um problema de classificação binária, contemplando análise exploratória dos dados, técnicas de pré-processamento e de tratamento do desbalanceamento de classes, treinamento e comparação de diferentes algoritmos de classificação, e avaliação de desempenho por meio de métricas apropriadas ao contexto desbalanceado, como precisão, revocação, F1-score e área sob a curva Precision-Recall. Espera-se, como resultado, identificar o modelo com melhor equilíbrio entre essas métricas, contribuindo para estratégias mais eficazes de prevenção a fraudes em meios de pagamento digitais.

Palavras-chave: fraude de cartão de crédito; aprendizado de máquina; classes desbalanceadas; scikit-learn.

Abstract

The growth of e-commerce and the digitalization of payment methods has significantly increased the volume of credit card transactions, also favoring a rise in financial fraud. Identifying fraudulent credit card transactions is a classic Machine Learning problem, marked by strong class imbalance, since fraudulent cases represent only a tiny fraction of all operations. This work aims to develop and evaluate classification models capable of identifying fraudulent credit card transactions using a public dataset, made available on the Kaggle platform, composed of 284,807 transactions performed by European cardholders in September 2013, of which only 492 (0.17%) are fraudulent. The study is justified by the economic relevance of automated fraud detection, since manual approaches or those based solely on fixed rules are insufficient given the volume and speed of current transactions. Methodologically, the work follows the Framework Option, employing the scikit-learn library to address a binary classification problem, encompassing exploratory data analysis, preprocessing techniques and class imbalance handling, training and comparison of different classification algorithms, and performance evaluation using metrics suited to the imbalanced context, such as precision, recall, F1-score, and the area under the Precision-Recall curve. The expected result is to identify the model with the best balance among these metrics, contributing to more effective fraud prevention strategies in digital payment systems.

1. Introdução

Contextualização

O crescimento do comércio eletrônico e a crescente digitalização dos meios de pagamento ampliaram de forma expressiva o volume de transações realizadas por cartão de crédito em todo o mundo. Esse cenário, embora traga inúmeros benefícios de praticidade e agilidade para consumidores e instituições financeiras, também favorece o aumento das fraudes financeiras, uma vez que fraudadores exploram falhas de segurança e o grande volume de operações para dissimular transações ilegítimas entre milhares de operações legítimas realizadas diariamente.

Nesse contexto, a identificação de transações fraudulentas de cartão de crédito representa um problema clássico e desafiador na área de Ciência de Dados e Aprendizado de Máquina, caracterizado principalmente pelo forte desbalanceamento entre as classes de interesse: as transações fraudulentas correspondem a uma parcela muito pequena do total de transações realizadas, o que dificulta a aplicação de abordagens tradicionais de classificação e exige técnicas específicas de tratamento de dados e de avaliação de desempenho dos modelos.

Este trabalho utiliza uma base de dados pública, amplamente utilizada na literatura e disponibilizada na plataforma Kaggle, contendo transações realizadas por portadores de cartão de

crédito europeus no mês de setembro de 2013. A base é composta por 284.807 transações, das quais apenas 492 (aproximadamente 0,17%) são fraudulentas. Por motivos de confidencialidade, a maioria das variáveis preditoras (V1 a V28) foi previamente transformada por meio da técnica de Análise de Componentes Principais (PCA), restando como variáveis originais apenas o tempo decorrido desde a primeira transação (Time) e o valor da transação (Amount), além da variável-alvo (Class), que indica se a transação é legítima (0) ou fraudulenta (1).

Justificativa

A detecção automatizada de fraudes é de grande relevância prática e econômica, uma vez que perdas financeiras decorrentes de fraudes em cartões de crédito impactam diretamente consumidores, comerciantes e instituições financeiras, além de comprometer a confiança dos usuários nos meios de pagamento digitais. Abordagens manuais ou baseadas exclusivamente em regras fixas mostram-se insuficientes diante do volume e da velocidade das transações atuais, bem como da constante evolução das estratégias utilizadas por fraudadores.

Diante disso, justifica-se a aplicação de técnicas de Aprendizado de Máquina como alternativa capaz de identificar padrões complexos e sutis nas transações, aprendendo a partir de dados históricos a distinguir comportamentos legítimos de comportamentos fraudulentos. Contudo, o forte desbalanceamento entre as classes exige cuidados metodológicos específicos — como o uso de métricas de avaliação adequadas (precisão, revocação, F1-score e área sob a curva Precision-Recall) e de técnicas de balanceamento de dados, o que reforça a relevância acadêmica e prática de um estudo dedicado a esse problema.

Objetivo

O objetivo geral deste trabalho é desenvolver e avaliar modelos de Aprendizado de Máquina capazes de identificar transações fraudulentas de cartão de crédito a partir de uma base de dados real e fortemente desbalanceada.

De forma específica, pretende-se: (i) realizar a análise exploratória dos dados, verificando a qualidade da base (valores ausentes, duplicidades e distribuição das variáveis), com destaque para o desbalanceamento entre as classes; (ii) aplicar técnicas de pré-processamento e de tratamento do desbalanceamento de classes; (iii) treinar e comparar diferentes algoritmos de classificação; e (iv) avaliar o desempenho dos modelos por meio de métricas apropriadas ao contexto de classes desbalanceadas, discutindo os resultados obtidos e suas implicações práticas.

Opção do projeto

Este trabalho se enquadra na Opção Framework, empregando a biblioteca scikit-learn para a resolução de um problema de classificação binária. Enquadra-se na modalidade de pesquisa aplicada, de natureza quantitativa e caráter experimental, cujo produto final consiste no desenvolvimento de um pipeline computacional de Aprendizado de Máquina para detecção de fraudes em transações de cartão de crédito. Optou-se por essa abordagem em razão da disponibilidade de uma base de dados real, consolidada na literatura, que permite tanto a experimentação prática de técnicas de tratamento de dados desbalanceados quanto a comparação objetiva de diferentes algoritmos por meio de métricas quantitativas de desempenho.

O restante deste documento está estruturado da seguinte forma: a Seção 2 apresenta o referencial teórico relacionado à detecção de fraudes e ao tratamento de dados desbalanceados; a

Seção 3 descreve a metodologia adotada, incluindo a análise exploratória dos dados e as etapas de pré-processamento; a Seção 4 apresenta e discute os resultados obtidos com os modelos treinados; e, por fim, a Seção 5 traz as conclusões do trabalho, suas contribuições, limitações e sugestões de trabalhos futuros.

2. Descrição do Problema

Fraude em cartão de crédito é um problema que todo banco enfrenta e que custa muito dinheiro por ano, tanto para instituições financeiras quanto para quem usa o cartão. A parte complicada desse problema não é só reconhecer o que é uma fraude, mas o fato de que fraudes são muito raras perto do total de transações: das 284.807 transações do dataset que estamos usando, apenas 492 são fraudulentas. Isso muda a forma como o problema precisa ser tratado, porque um modelo que simplesmente "chutasse" que toda transação é legítima já acertaria mais de 99% das vezes, mesmo sem detectar nenhuma fraude de verdade.

A ideia do projeto é usar técnicas de IA para treinar um modelo que consiga separar transações normais das fraudulentas, usando as colunas do dataset (V1 a V28, que já vêm tratadas por PCA, além de Amount e Time). Achemos esse problema interessante justamente porque ele junta vários pontos que estamos aprendendo: como lidar com dados desbalanceados, como preparar os dados antes de treinar o modelo, e como avaliar se o modelo é bom sem cair na armadilha de olhar só para a acurácia (que aqui não diz muita coisa sozinha).

3. Ética e Responsabilidade no uso da IA

Usar IA para detectar fraude é útil, mas também traz alguns pontos que valem a pena discutir.

O primeiro é a privacidade dos dados. O próprio dataset já foi anonimizado pelos criadores (as variáveis passaram por PCA), o que mostra a preocupação em não expor informações sensíveis de quem fez as transações. Isso é algo que qualquer projeto que mexe com dados financeiros precisa levar a sério.

Outro ponto é o impacto de um erro do modelo. Se ele classifica uma compra normal como fraude (falso positivo), a pessoa pode ter o cartão bloqueado sem motivo, o que é chato e pode até causar problema em uma emergência. Já se o modelo deixa passar uma fraude de verdade (falso negativo), quem perde é o banco e o cliente. Existe, então, um equilíbrio delicado entre ser rigoroso demais e permissivo demais, e isso vai influenciar as escolhas que faremos mais adiante no projeto.

Há também a questão do desbalanceamento em si: como existem poucos exemplos de fraude, há o risco de o modelo aprender de forma tendenciosa ou não generalizar bem para casos novos. Por isso, mais adiante vamos precisar tratar isso com cuidado (técnicas como SMOTE ou ajuste de peso das classes) e deixar claro no relatório quais são as limitações do que conseguimos fazer.

Por fim, um ponto que achamos importante registrar: como esse tipo de sistema afeta diretamente a vida das pessoas (bloquear ou não uma compra), o ideal é que o modelo não seja uma "caixa-preta" total, e que dê para entender minimamente por que ele tomou certa decisão —

isso inclusive é algo que a LGPD exige em situações parecidas. E claro, esse projeto é apenas acadêmico, então não estamos propondo isso como algo pronto para uso real por um banco, apenas estudando o problema com as ferramentas que temos até agora.

4. Referencial Teórico

O referencial teórico apresenta a base conceitual relacionada ao problema de pesquisa e aos objetivos do trabalho. Apresenta, portanto, conteúdos teóricos essenciais que ajudam o leitor a entender conceitos importantes e necessários para o correto entendimento do projeto.

Nessa seção, devem ser apresentados tópicos que possibilitem compreender o estado da arte da área de pesquisa. No entanto, não deve ser entendido como um conjunto de sinopses e resumos de artigos ou livros. Portanto, deve ser construído pelo autor de forma fluída e compreensível, sempre indicando como as obras referenciadas contribuíram para o desenvolvimento do projeto.

Recomenda-se que essa seção seja organizada em formato de funil, no sentido de que o tema mais genérico preceda os temas específicos.

5. Metodologia

A pesquisa desenvolvida neste trabalho tem caráter quantitativo e experimental, sendo conduzida a partir de uma base de dados secundária, pública e já consolidada na literatura, disponibilizada na plataforma Kaggle (mlg-ulb/creditcardfraud). Não houve, portanto, coleta primária de dados: a base foi obtida diretamente do repositório público, contendo transações realizadas por portadores de cartão de crédito europeus em setembro de 2013.

O tratamento dos dados seguiu as seguintes etapas: inicialmente, foi realizada uma checagem de qualidade da base, verificando a existência de valores ausentes e de registros duplicados. Em seguida, as variáveis Amount e Time — as únicas que não haviam passado pela transformação PCA aplicada pelos autores originais do dataset — foram normalizadas por meio de StandardScaler, de modo a ficarem na mesma escala das demais variáveis (V1 a V28). Os dados foram então divididos em conjuntos de treino (80%) e teste (20%), de forma estratificada, garantindo que a proporção de transações fraudulentas fosse preservada em ambos os conjuntos, dado o forte desbalanceamento das classes.

Para lidar com esse desbalanceamento, foi aplicada a técnica SMOTE (Synthetic Minority Over-sampling Technique) exclusivamente sobre o conjunto de treino, gerando exemplos sintéticos da classe minoritária (fraude) a partir de seus vizinhos mais próximos, evitando assim o viés de um modelo que classificasse indiscriminadamente todas as transações como legítimas. Como abordagem complementar a ser avaliada, também será considerado o uso do parâmetro `class_weight='balanced'` diretamente nos algoritmos de classificação, sem alteração da distribuição original dos dados de treino.

Na etapa de modelagem, prevista para a fase seguinte do projeto, serão treinados e comparados diferentes algoritmos de classificação — Regressão Logística, Random Forest e

XGBoost —, empregando a biblioteca scikit-learn. A avaliação dos modelos será conduzida com base em métricas adequadas ao contexto de classes desbalanceadas, como precisão, revocação (recall), F1-score e a área sob a curva Precisão-Revocação (AUPRC), evitando o uso isolado da acurácia, que se mostra enganosa nesse cenário.

Resultados Esperados

Espera-se obter um modelo de classificação capaz de identificar transações fraudulentas com bom equilíbrio entre precisão e revocação, priorizando a capacidade de detectar o maior número possível de fraudes (alta revocação) sem gerar um volume excessivo de falsos positivos, que impactariam negativamente a experiência dos clientes legítimos. Entre os algoritmos avaliados, espera-se que modelos baseados em ensemble, como Random Forest e XGBoost, apresentem desempenho superior ao da Regressão Logística, por serem capazes de capturar relações mais complexas e não lineares entre as variáveis. Ao final, pretende-se identificar o modelo com o melhor desempenho segundo a métrica AUPRC, discutindo suas limitações e as possíveis melhorias a serem exploradas na etapa final do projeto.

6. Resultados e discussão

Os resultados obtidos com a pesquisa devem ser descritos nessa seção. Recomenda-se o uso de figuras e tabelas para apresentar de forma organizada esses resultados. Se for o caso, as diferenças dos resultados alcançados em comparação com o estado da arte podem ser descritas. Além disso, uma análise crítica dos resultados deve ser conduzida, apontando os pontos positivos e negativos encontrados por meio da metodologia proposta.

7. Conclusão

A conclusão não deve apresentar resultados sem acompanhamento do problema de pesquisa e dos objetivos do projeto.

A conclusão deve iniciar com um breve relato do trabalho, lembrando o leitor do problema de pesquisa, dos objetivos e das ferramentas metodológicas. Em seguida, os resultados devem ser sumarizados com o objetivo de responder à questão do problema de pesquisa. As contribuições da pesquisa e suas limitações devem ser pontuadas em sequência. Por fim, devem ser apresentados os possíveis trabalhos futuros que podem ser realizados em uma sequência do próprio projeto ou que podem ser inspirados pelo método ou técnicas propostas.

6. Referências bibliográficas

As citações e as referências bibliográficas devem seguir as normas definidas pela ABNT - NBR 6023 (ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS, 2018). Apenas os trabalhos citados devem ser indicados.

Para citações em linha, em que o autor é citado de forma corrida, deve ser utilizado o estilo considerando o sobrenome dos autores com apenas a primeira letra maiúscula, seguido da data de publicação da obra entre parênteses. Exemplos: Segundo Chawla et al. (2002)[...]; De acordo com Lemaître, Nogueira e Aridas (2017)[...].

Para citações em final de parágrafo, a citação deve ser realizada entre parênteses, considerando o sobrenome do autor completamente em maiúsculo, seguido pela data de publicação. Os autores e as obras devem ser separados por ponto e vírgula (;), já a data deve ser separada por vírgula (.). Exemplos: (KAGGLE, 2018), (CHAWLA et al., 2002; LEMAÎTRE; NOGUEIRA; ARIDAS, 2017).

Referências

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. NBR 6023: informação e documentação: referências: elaboração. Rio de Janeiro: ABNT, 2018.

KAGGLE. Credit Card Fraud Detection. 2018. Disponível em: <https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud>. Acesso em: 13 de setembro de 2026.

SCIKIT-LEARN. scikit-learn: machine learning in Python. 2024. Disponível em: <https://scikit-learn.org/>. Acesso em: 13 de setembro de 2026.

LEMAÎTRE, G.; NOGUEIRA, F.; ARIDAS, C. K. Imbalanced-learn: A Python Toolbox to Tackle the Curse of Imbalanced Datasets in Machine Learning. *Journal of Machine Learning Research*, v. 18, n. 17, p. 1-5, 2017.

CHAWLA, N. V. et al. SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, v. 16, p. 321-357, 2002.

UNIVERSIDADE PRESBITERIANA MACKENZIE. Guia do TCC: Orientações gerais para a elaboração do trabalho de conclusão dos cursos de graduação. São Paulo: UPM, 2021.